DESARROLLO EXÁMEN MÓDULO INTERMEDIO - Python for Data Science

In [1]:
```
#Instalando las librerías necesarias

import os   #Cambiar directorio de trabajo
import scipy
#Manipulación de Datos
import numpy as np
import pandas as pd

#Gráficos
import matplotlib.pyplot as plt
import seaborn as sns

#Preprocesado y modelado
from sklearn.model_selection import train_test_split #Para particionamiento en Datos de Entrenamie
from sklearn.linear_model import LogisticRegression  #Para Análisis de Regresión Logística
from sklearn.metrics import mean_squared_error       #Calcula el error cuadratico medio
from sklearn.metrics import classification_report    #Para construir un reporte de clasificación
from sklearn.metrics import confusion_matrix         #Para construir la matriz de confusión
from sklearn.feature_selection import RFE            #Para medir la importancia de las variables i
from sklearn.model_selection import cross_val_score  #Para llevar a cabo CrossValidation
from sklearn import metrics
from sklearn.metrics import roc_curve,auc
from imblearn.under_sampling import RandomUnderSampler

#Para distintas métricas de evaluación
import statsmodels.api as sm
import statsmodels.formula.api as smf
import math as m

from sklearn.discriminant_analysis import LinearDiscriminantAnalysis, QuadraticDiscriminantAnalysi
from sklearn.metrics import confusion_matrix, classification_report, precision_score

#Just In Case
import warnings
warnings.filterwarnings('ignore')
```

In [2]:
```
#Estableciendo directorio
os.chdir("D:\Social Data Consulting\Python for Data Science\data")
```

In [3]:
```
wines='wines_types.csv'
df_wines = pd.read_csv(wines)
df_wines.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 6497 entries, 0 to 6496
Data columns (total 12 columns):
 #   Column                Non-Null Count  Dtype  
---  ------                --------------  -----  
 0   fixed acidity         6497 non-null   float64
 1   volatile acidity      6497 non-null   float64
 2   citric acid           6497 non-null   float64
 3   residual sugar        6497 non-null   float64
 4   chlorides             6497 non-null   float64
 5   free sulfur dioxide   6497 non-null   float64
 6   total sulfur dioxide  6497 non-null   float64
 7   density               6497 non-null   float64
 8   pH                    6497 non-null   float64
 9   sulphates             6497 non-null   float64
 10  alcohol               6497 non-null   float64
 11  wine_type             6497 non-null   object 
dtypes: float64(11), object(1)
memory usage: 609.2+ KB
```

In [4]:
```
df_wines.head()
```

Out[4]:

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	wine_type
0	7.0	0.17	0.74	12.8	0.045	24.0	126.0	0.99420	3.26	0.38	12.2	white
1	7.7	0.64	0.21	2.2	0.077	32.0	133.0	0.99560	3.27	0.45	9.9	red
2	6.8	0.39	0.34	7.4	0.020	38.0	133.0	0.99212	3.18	0.44	12.0	white
3	6.3	0.28	0.47	11.2	0.040	61.0	183.0	0.99592	3.12	0.51	9.5	white
4	7.4	0.35	0.20	13.9	0.054	63.0	229.0	0.99888	3.11	0.50	8.9	white

In [5]:
```
columns=df_wines.columns.to_list()
target=['wine_type']
x=[x for x in columns if x not in target]
```

1. Codificar las variable wine_type (white= 1 y red=2) y particionar los datos en entrenamiento (75%) y prueba (25%)

In [6]:
```
#Codificacion de la variable wine_type (white=1 y red=2)
df_wines.wine_type=np.where(df_wines.wine_type=="red",2,1)

#Particionamiento de la data, definimos X e y
X=df_wines.iloc[:,0:df_wines.shape[1]-1].values
y=df_wines.iloc[:,df_wines.shape[1]-1].values

# Generamos nuestra data de entrenamiento y testeo
X_train,X_test,y_train,y_test=train_test_split(X,
                                               y,
                                              test_size=0.25,
                                              stratify=y,
                                              random_state=2020)
```

In [7]:
```
pd.value_counts(df_wines['wine_type'])
```

Out[7]:
```
1    4898
2    1599
Name: wine_type, dtype: int64
```

In [8]:
```
frecuencias=pd.value_counts(df_wines['wine_type'],sort=True)*100/len(df_wines)
frecuencias.plot(kind='bar')
plt.title('Distribución Tipos de vino')
plt.show()
```

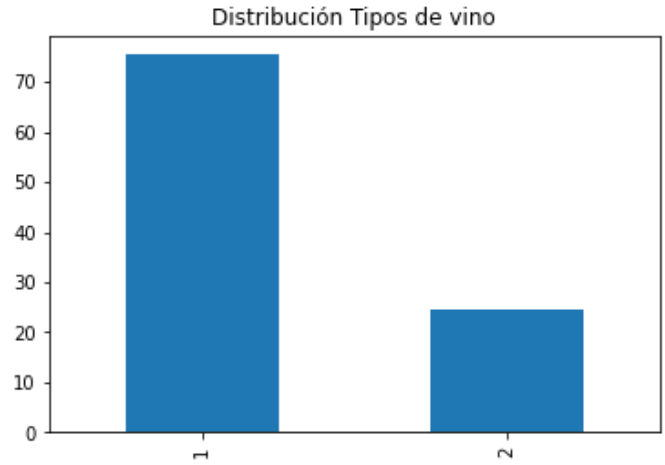

BALANCEO DE DATOS

In [9]:
```
rus=RandomUnderSampler(sampling_strategy=0.8,random_state=2020)
x_train_us,y_train_us=rus.fit_sample(X_train,y_train)
```

In [10]:
```
x_train_us_df=pd.DataFrame(x_train_us,columns=x)
y_train_us_df=pd.DataFrame(y_train_us,columns=target)

xtest_df=pd.DataFrame(X_test,columns=x)
ytest_df=pd.DataFrame(y_test,columns=target)

df_wines_train_us=pd.concat([x_train_us_df,y_train_us_df],axis=1)
df_wines_test=pd.concat([xtest_df,ytest_df],axis=1)
```

In [11]:
```
frecuencias=pd.value_counts(df_wines_train_us['wine_type'],sort=True)*100/len(df_wines_train_us)
frecuencias.plot(kind='bar')
plt.title('Distribución Tipos de vino')
plt.show()
```

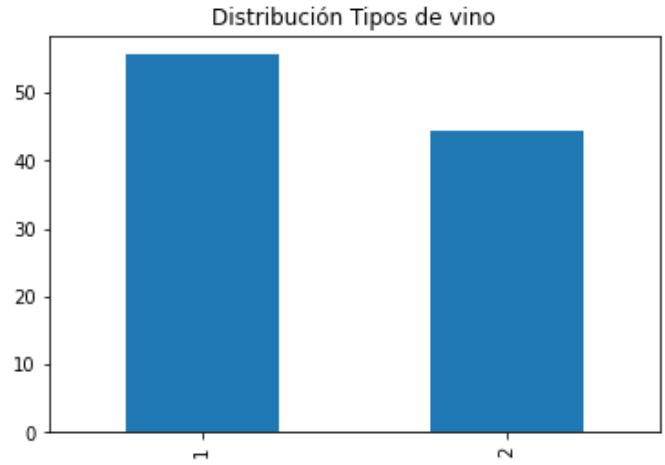

2. Modelar el tipo de vino (wine_type) en función a las variables predictoras haciendo

uso del modelo de regresión logístico. Considerar para las predicciones un punto de corte de 0.6

In [12]:
```
logistic_model=LogisticRegression(max_iter=1000)
logistic_model.fit(x_train_us,y_train_us)
```

Out[12]:
```
LogisticRegression(max_iter=1000)
```

Usando Cross Validation para evaluar la estabilidad de los datos

In [13]:
```
score=cross_val_score(estimator=logistic_model,
                      X=x_train_us,
                      y=y_train_us,
                      scoring="accuracy",
                      cv=10) #numero de particiones
```

In [14]:
```
print('La media de accuracy es: ', score.mean().round(2))
```

```
La media de accuracy es:  0.98
```

In [15]:
```
plt.plot(list(range(1,11)),score)
plt.ylim([0.6,1.5])
plt.hlines(score.mean(),xmin=1,xmax=10,color='red')
plt.title('Convergencia(CrossValidation) del Accuracy -Regresion Logistica')
plt.show()
```

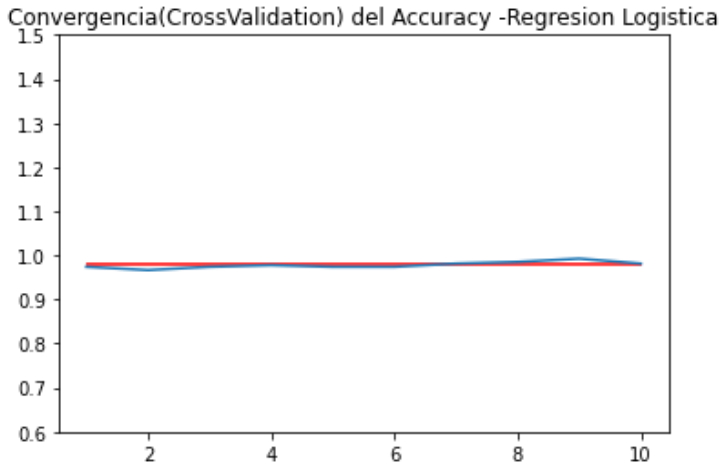

In [16]:
```
prob_train=logistic_model.predict_proba(x_train_us)
prob_df_train_log=pd.DataFrame(prob_train[:,1],columns=['prob y=2'])
```

Punto de Corte

In [17]:
```
punto_corte=0.6
prob_df_train_log['prediccion']=np.where(prob_df_train_log['prob y=2']>punto_corte,2,1)
prob_df_train_log.head()
```

Out[17]:

	prob y=2	prediccion
0	0.000194	1
1	0.002831	1
2	0.003950	1
3	0.075573	1
4	0.042408	1

3. Aplicar los parámetros del modelo de entrenamiento a los datos de testeo, considerar para las predicciones un punto de corte de 0.6

In [18]:
```
prob_test=logistic_model.predict_proba(X_test)
prob_df_test_log=pd.DataFrame(prob_test[:,1],columns=['prob y=2'])
```

Punto de Corte

In [19]:
```
punto_corte=0.6
prob_df_test_log['prediccion']=np.where(prob_df_test_log['prob y=2']>punto_corte,2,1)
prob_df_test_log.head()
```

Out[19]:

	prob y=2	prediccion
0	0.030373	1
1	0.534858	1
2	0.009609	1
3	0.002654	1
4	0.006526	1

4. Evaluar el modelo de regresión logístico haciendo uso de las métricas de accuracy, sensibilidad. especificidad, auc y curva ROC

Metricas para data de entrenamiento

In [20]:
```
cm_train=pd.crosstab(y_train_us,prob_df_train_log['prediccion'])
cm_train
```

Out[20]:

prediccion	1	2
row_0		
1	1489	9
2	49	1150

In [21]:
```
VP_train=cm_train[2][2]
VN_train=cm_train[1][1]
FP_train=cm_train[1][2]
FN_train=cm_train[2][1]
```

In [22]:
```
accuracy_train_log=(VP_train+VN_train)/(VP_train+VN_train+FN_train+FP_train)
print('El Accuracy para la Data de Entrenamiento es:',accuracy_train_log.round(3))
```

```
El Accuracy para la Data de Entrenamiento es: 0.978
```

In [23]:
```
sensibilidad_train_log=(VP_train)/(VP_train+FN_train)
print('La Sensibilidad para la Data de Entrenamiento es:',sensibilidad_train_log.round(3))
```

```
La Sensibilidad para la Data de Entrenamiento es: 0.992
```

In [24]:
```
especificidad_train_log=(VN_train)/(VN_train+FP_train)
print('La Especificidad para la Data de Entrenamiento es:',especificidad_train_log.round(3))
```

```
La Especificidad para la Data de Entrenamiento es: 0.968
```

In [25]:
```
#Para calcular de la curva ROC y AUC, la función roc_curve exige que las categorias sean 0 y 1
y_train_us_cat=np.where(y_train_us==1,0,1)
prob_df_train_log['prediccion_cat']=np.where(prob_df_train_log['prediccion']==1,0,1)

fpr,tpr,thresholds=roc_curve(y_train_us_cat,prob_df_train_log['prediccion_cat'])
auc_train_log=auc(fpr,tpr)
print('El area Bajo la Curva(AUC) para Data de Entrenamiento es: ',auc_train_log.round(3))
```

```
El area Bajo la Curva(AUC) para Data de Entrenamiento es:  0.977
```

GRÁFICA CURVA ROC data entrenamiento

In [26]:
```
plt.figure(figsize=(5,5),dpi=100)
plt.plot(fpr,tpr,linestyle='-',label='Logistic(auc=%0.3f)'%auc_train_log)
plt.title('Curva ROC para data entrenamiento')
plt.xlabel('Ratio False positivo')
plt.ylabel('Ratio Verdarero positivo')
plt.legend()

x=[i*0.01 for i in range(100)]
y=[i*0.01 for i in range(100)]
plt.plot(x,y)
plt.show()
```

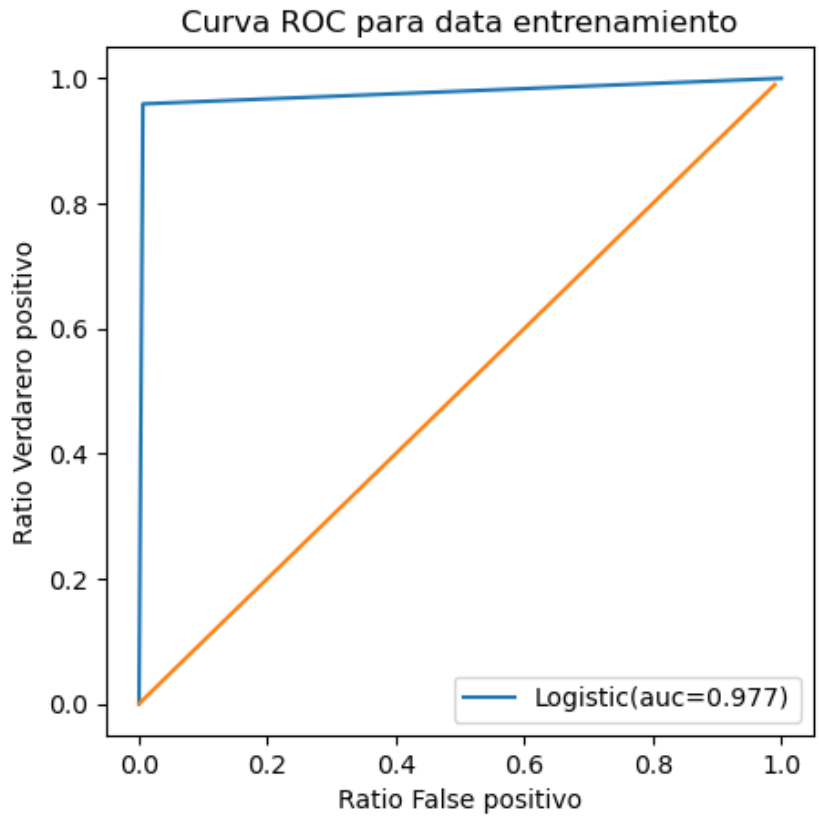

Metricas para data de testeo

In [27]:
```
cm_test=pd.crosstab(y_test,prob_df_test_log['prediccion'])
cm_test
```

Out[27]:

prediccion	1	2
row_0		
1	1214	11
2	13	387

In [28]:
```
VP_test=cm_test[2][2]
VN_test=cm_test[1][1]
FP_test=cm_test[1][2]
FN_test=cm_test[2][1]
```

In [29]:
```
accuracy_test_log=(VP_test+VN_test)/(VP_test+VN_test+FN_test+FP_test)
print('El Accuracy para la Data de Entrenamiento es:',accuracy_test_log.round(3))
```

```
El Accuracy para la Data de Entrenamiento es: 0.985
```

In [30]:
```
sensibilidad_test_log=(VP_test)/(VP_test+FN_test)
print('La Sensibilidad para la Data de Entrenamiento es:',sensibilidad_test_log.round(3))
```

```
La Sensibilidad para la Data de Entrenamiento es: 0.972
```

In [31]:
```
especificidad_test_log=(VN_test)/(VN_test+FP_test)
print('La Especificidad para la Data de Entrenamiento es:',especificidad_test_log.round(3))
```

```
La Especificidad para la Data de Entrenamiento es: 0.989
```

In [32]:
```
#Para calcular de la curva ROC y AUC, la función roc_curve exige que las categorias sean 0 y 1
y_test_cat=np.where(y_test==1,0,1)
prob_df_test_log['prediccion_cat']=np.where(prob_df_test_log['prediccion']==1,0,1)

fpr,tpr,thresholds=roc_curve(y_test_cat,prob_df_test_log['prediccion_cat'])
auc_test_log=auc(fpr,tpr)
print('El area Bajo la Curva(AUC) para Data de Testeo es: ',auc_test_log.round(3))
```

```
El area Bajo la Curva(AUC) para Data de Testeo es:  0.979
```

GRÁFICA CURVA ROC data testeo

In [33]:
```
plt.figure(figsize=(5,5),dpi=100)
plt.plot(fpr,tpr,linestyle='-',label='Logistic(auc=%0.3f)'%auc_test_log)
plt.title('Curva ROC para data Testeo')
plt.xlabel('Ratio False positivo')
plt.ylabel('Ratio Verdarero positivo')
plt.legend()

x=[i*0.01 for i in range(100)]
y=[i*0.01 for i in range(100)]
plt.plot(x,y)
plt.show()
```

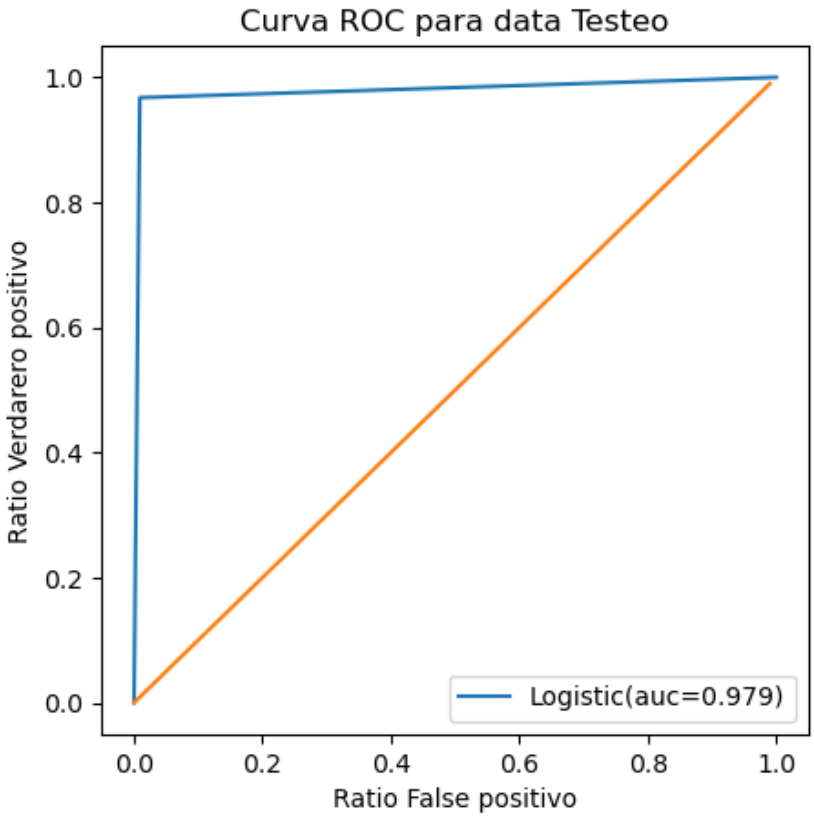

5. Modelar el tipo de vino (wine_type) en función a las variables predictoras haciendo uso del modelo de análisis discriminante lineal. Considerar para las predicciones un punto de corte de 0.6.

In [34]:
```
#Creamos el objeto de clase LinearDiscriminantAnalysis()
lda_model=LinearDiscriminantAnalysis()
#Ajustamos el modelo para aprender con la data balanceada
lda_model.fit(x_train_us,y_train_us)
```

Out[34]:
```
LinearDiscriminantAnalysis()
```

Usando Cross Validation para evaluar la estabilidad de los datos

In [35]:
```
score=cross_val_score(estimator=lda_model,
                      X=x_train_us,
                      y=y_train_us,
                      scoring="accuracy",
                      cv=10) #numero de particiones
```

In [36]:
```
print('La media de accuracy es: ', score.mean().round(2))
```

```
La media de accuracy es:  0.99
```

In [37]:
```
plt.plot(list(range(1,11)),score)
plt.ylim([0.6,1.2])
plt.hlines(score.mean(),xmin=1,xmax=10,color='red')
plt.title('Convergencia(CrossValidation) del Accuracy -Analisis Discriminante Lineal')
plt.show()
```

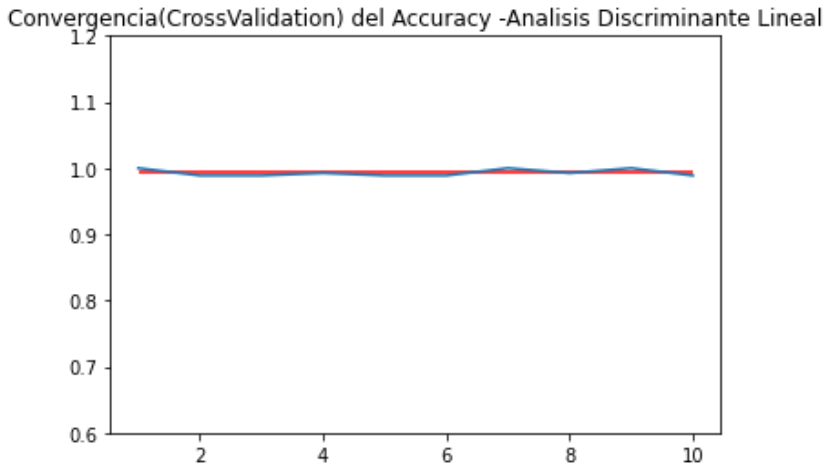

In [38]:
```
prob_train=lda_model.predict_proba(x_train_us)
prob_df_train_lda=pd.DataFrame(prob_train[:,1],columns=['prob y=2'])
```

Punto de Corte 0.6

In [39]:
```
punto_corte=0.6
prob_df_train_lda['prediccion']=np.where(prob_df_train_lda['prob y=2']>punto_corte,2,1)
prob_df_train_lda.head()
```

Out[39]:

	prob y=2	prediccion
0	5.759352e-09	1
1	3.777151e-08	1
2	1.061875e-07	1
3	3.969924e-05	1
4	4.883100e-07	1

6. Aplicar los parámetros del modelo de entrenamiento a los datos de testeo, considerar para las predicciones un punto de corte de 0.6.

In [40]:
```
prob_test=lda_model.predict_proba(X_test)
prob_df_test_lda=pd.DataFrame(prob_test[:,1],columns=['prob y=2'])
```

Punto de Corte 0.6

In [41]:
```
punto_corte=0.6
prob_df_test_lda['prediccion']=np.where(prob_df_test_lda['prob y=2']>punto_corte,2,1)
prob_df_test_lda.head()
```

Out[41]:

	prob y=2	prediccion
0	1.020520e-06	1
1	9.174025e-06	1
2	3.164813e-09	1
3	4.063813e-08	1
4	4.755967e-09	1

7. Modelar el tipo de vino (wine_type) en función a las variables predictoras haciendo uso del modelo de análisis discriminante cuadrático. Considerar para las predicciones un punto de corte de 0.6.

In [42]:
```
cda_model=QuadraticDiscriminantAnalysis()
cda_model.fit(x_train_us,y_train_us)
```

Out[42]:
```
QuadraticDiscriminantAnalysis()
```

Usando Cross Validation para evaluar la estabilidad de los datos

In [43]:
```
score=cross_val_score(estimator=cda_model,
                      X=x_train_us,
                      y=y_train_us,
                      scoring="accuracy",
                      cv=10) #numero de particiones
```

In [44]:
```
print('La media de accuracy es: ', score.mean().round(3))
```

```
La media de accuracy es:  0.986
```

In [45]:
```
plt.plot(list(range(1,11)),score)
plt.ylim([0.6,1.2])
plt.hlines(score.mean(),xmin=1,xmax=10,color='red')
plt.title('Convergencia(CrossValidation) del Accuracy -Analisis Discriminante Cuadratico(QDA)')
plt.show()
```

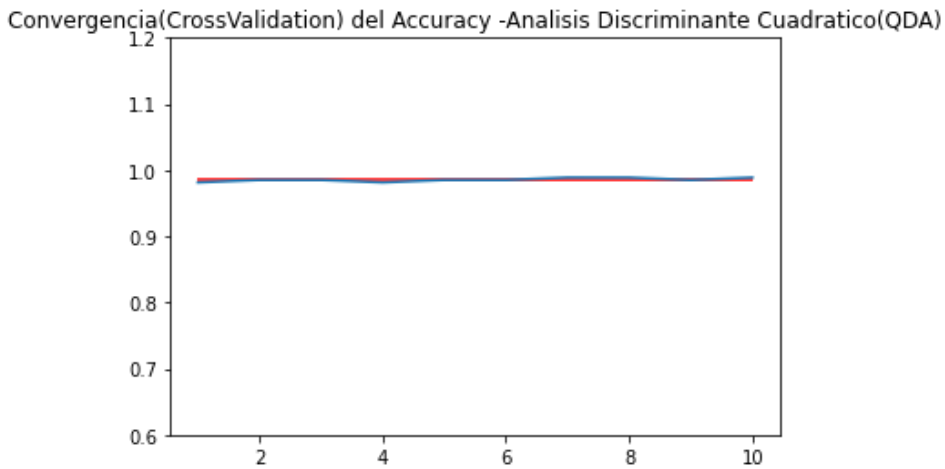

In [46]:
```
prob_train=cda_model.predict_proba(x_train_us)
prob_df_train_cda=pd.DataFrame(prob_train[:,1],columns=['prob y=2'])
```

Punto de Corte 0.6

In [47]:
```
punto_corte=0.6
prob_df_train_cda['prediccion']=np.where(prob_df_train_cda['prob y=2']>punto_corte,2,1)
prob_df_train_cda.head()
```

Out[47]:

	prob y=2	prediccion
0	4.612838e-31	1
1	2.084180e-09	1
2	4.206718e-24	1
3	1.341687e-04	1
4	7.487312e-05	1

8. Aplicar los parámetros del modelo de entrenamiento a los datos de testeo, considerar para las predicciones un punto de corte de 0.6.

In [48]:
```
prob_test=cda_model.predict_proba(X_test)
prob_df_test_cda=pd.DataFrame(prob_test[:,1],columns=['prob y=2'])
```

Punto de Corte 0.6

In [49]:
```
punto_corte=0.6
prob_df_test_cda['prediccion']=np.where(prob_df_test_cda['prob y=2']>punto_corte,2,1)
prob_df_test_cda.head()
```

Out[49]:

	prob y=2	prediccion
0	6.903395e-06	1
1	8.425247e-08	1
2	1.564088e-06	1
3	8.814704e-06	1
4	7.519831e-10	1

9. Evaluar los modelos de analisis discriminante lineal y cuadrático haciendo uso de las métricas de accuracy, sensibilidad. especificidad, auc y curva ROC

Modelo discriminante Lineal (LDA)

Métricas para Data de Entrenamiento

In [50]:
```
cm_train=pd.crosstab(y_train_us,prob_df_train_lda["prediccion"])
cm_train
```

Out[50]:

prediccion	1	2
row_0		
1	1492	6
2	13	1186

In [51]:
```
VP_train=cm_train[2][2]
VN_train=cm_train[1][1]
FP_train=cm_train[1][2]
FN_train=cm_train[2][1]
```

In [52]:
```
accuracy_train_lda=(VP_train+VN_train)/(VP_train+VN_train+FN_train+FP_train)
print('El Accuracy para la Data de Entrenamiento es:',accuracy_train_lda.round(3))
```

```
El Accuracy para la Data de Entrenamiento es: 0.993
```

In [53]:
```
sensibilidad_train_lda=(VP_train)/(VP_train+FN_train)
print('La Sensibilidad para la Data de Entrenamiento es:',sensibilidad_train_lda.round(3))
```

```
La Sensibilidad para la Data de Entrenamiento es: 0.995
```

In [54]:
```
especificidad_train_lda=(VN_train)/(VN_train+FP_train)
print('La Especificidad para la Data de Entrenamiento es:',especificidad_train_lda.round(3))
```

```
La Especificidad para la Data de Entrenamiento es: 0.991
```

In [55]:
```
#Para calcular de la curva ROC y AUC, la función roc_curve exige que las categorias sean 0 y 1
y_train_us_cat=np.where(y_train_us==1,0,1)
prob_df_train_lda['prediccion_cat']=np.where(prob_df_train_lda['prediccion']==1,0,1)

fpr,tpr,thresholds=roc_curve(y_train_us_cat,prob_df_train_lda['prediccion_cat'])
auc_train_lda=auc(fpr,tpr)
print('El area Bajo la Curva(AUC) para Data de Entrenamiento es: ',auc_train_lda.round(3))
```

```
El area Bajo la Curva(AUC) para Data de Entrenamiento es:  0.993
```

GRÁFICA CURVA ROC data entrenamiento

In [56]:
```
plt.figure(figsize=(5,5),dpi=100)
plt.plot(fpr,tpr,linestyle='-',label='Logistic(auc=%0.3f)'%auc_train_lda)
plt.title('Curva ROC para data entrenamiento')
plt.xlabel('Ratio Falso positivo')
plt.ylabel('Ratio Verdarero positivo')
plt.legend()

x=[i*0.01 for i in range(100)]
y=[i*0.01 for i in range(100)]
plt.plot(x,y)
plt.show()
```

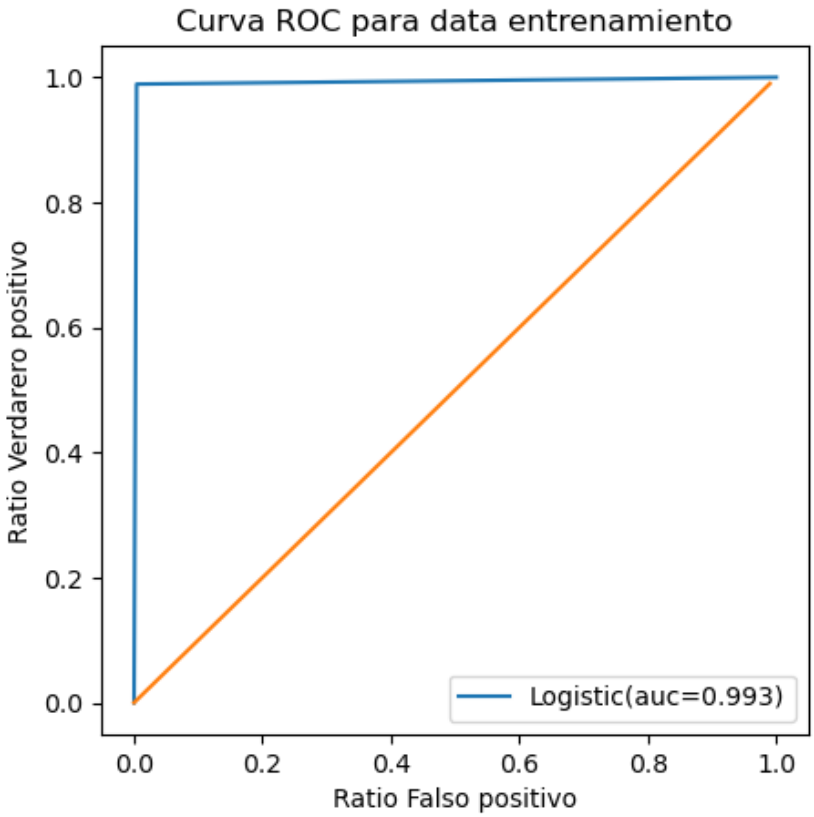

Métricas para Data de Testeo

In [57]:
```
cm_test=pd.crosstab(y_test,prob_df_test_lda["prediccion"])
cm_test
```

Out[57]:

prediccion	1	2
row_0		
1	1219	6
2	5	395

In [58]:
```
VP_test=cm_test[2][2]
VN_test=cm_test[1][1]
FP_test=cm_test[1][2]
FN_test=cm_test[2][1]
```

In [59]:
```
accuracy_test_lda=(VP_test+VN_test)/(VP_test+VN_test+FN_test+FP_test)
print('El Accuracy para la Data de Entrenamiento es:',accuracy_test_lda.round(3))
```

```
El Accuracy para la Data de Entrenamiento es: 0.993
```

In [60]:
```
sensibilidad_test_lda=(VP_test)/(VP_test+FN_test)
print('La Sensibilidad para la Data de Entrenamiento es:',sensibilidad_test_lda.round(3))
```

```
La Sensibilidad para la Data de Entrenamiento es: 0.985
```

In [61]:
```
especificidad_test_lda=(VN_test)/(VN_test+FP_test)
print('La Especificidad para la Data de Entrenamiento es:',especificidad_test_lda.round(3))
```

```
La Especificidad para la Data de Entrenamiento es: 0.996
```

In [62]:
```
#Para calcular de la curva ROC y AUC, la función roc_curve exige que las categorias sean 0 y 1
y_test_cat=np.where(y_test==1,0,1)
prob_df_test_lda['prediccion_cat']=np.where(prob_df_test_lda['prediccion']==1,0,1)

fpr,tpr,thresholds=roc_curve(y_test_cat,prob_df_test_lda['prediccion_cat'])
auc_test_lda=auc(fpr,tpr)
print('El area Bajo la Curva(AUC) para Data de Testeo es: ',auc_test_lda.round(3))
```

```
El area Bajo la Curva(AUC) para Data de Testeo es:  0.991
```

GRÁFICA CURVA ROC data testeo

In [63]:
```
plt.figure(figsize=(5,5),dpi=100)
plt.plot(fpr,tpr,linestyle='-',label='Logistic(auc=%0.3f)'%auc_test_lda)
plt.title('Curva ROC para data Testeo')
plt.xlabel('Ratio False positivo')
plt.ylabel('Ratio Verdarero positivo')
plt.legend()

x=[i*0.01 for i in range(100)]
y=[i*0.01 for i in range(100)]
plt.plot(x,y)
plt.show()
```

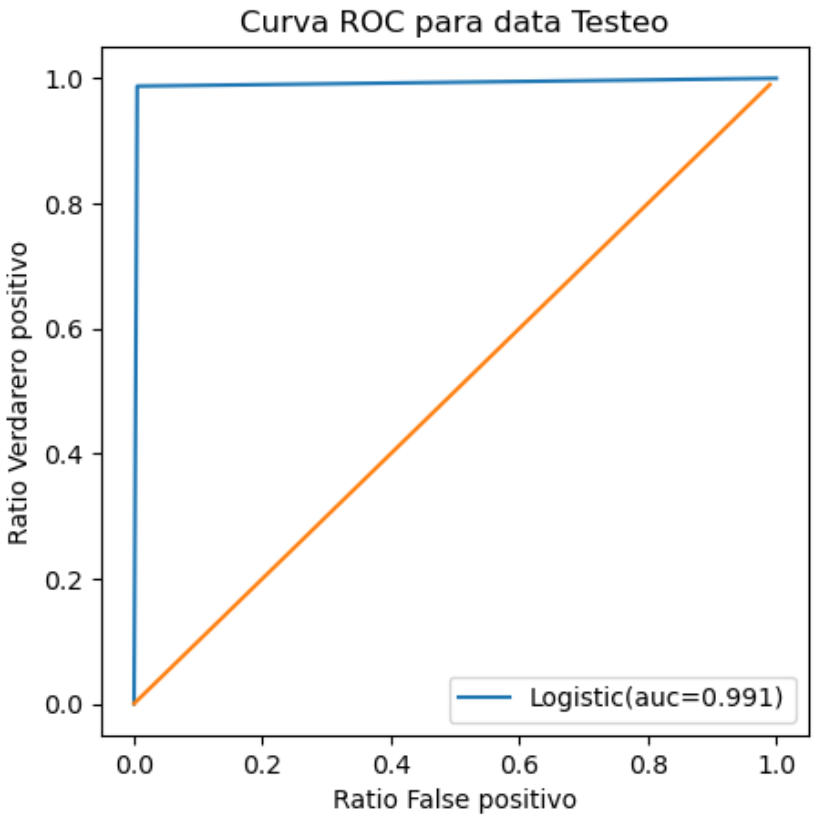

Modelo discriminante Cuadrático (QDA)

Métricas para Data de Entrenamiento

In [64]:
```
cm_train=pd.crosstab(y_train_us,prob_df_train_cda["prediccion"])
cm_train
```

Out[64]:

prediccion	1	2
row_0		
1	1474	24
2	13	1186

In [65]:
```
VP_train=cm_train[2][2]
VN_train=cm_train[1][1]
FP_train=cm_train[1][2]
FN_train=cm_train[2][1]
```

In [66]:
```
accuracy_train_cda=(VP_train+VN_train)/(VP_train+VN_train+FN_train+FP_train)
print('El Accuracy para la Data de Entrenamiento es:',accuracy_train_cda.round(3))
```

```
El Accuracy para la Data de Entrenamiento es: 0.986
```

In [67]:
```
sensibilidad_train_cda=(VP_train)/(VP_train+FN_train)
print('La Sensibilidad para la Data de Entrenamiento es:',sensibilidad_train_cda.round(3))
```

```
La Sensibilidad para la Data de Entrenamiento es: 0.98
```

In [68]:
```
especificidad_train_cda=(VN_train)/(VN_train+FP_train)
print('La Especificidad para la Data de Entrenamiento es:',especificidad_train_cda.round(3))
```

```
La Especificidad para la Data de Entrenamiento es: 0.991
```

In [69]:
```
#Para calcular de la curva ROC y AUC, la función roc_curve exige que las categorias sean 0 y 1
y_train_us_cat=np.where(y_train_us==1,0,1)
prob_df_train_cda['prediccion_cat']=np.where(prob_df_train_cda['prediccion']==1,0,1)

fpr,tpr,thresholds=roc_curve(y_train_us_cat,prob_df_train_cda['prediccion_cat'])
auc_train_cda=auc(fpr,tpr)
print('El area Bajo la Curva(AUC) para Data de Entrenamiento es: ',auc_train_cda.round(3))
```

```
El area Bajo la Curva(AUC) para Data de Entrenamiento es:  0.987
```

GRÁFICA CURVA ROC data entrenamiento

In [70]:
```
plt.figure(figsize=(5,5),dpi=100)
plt.plot(fpr,tpr,linestyle='-',label='Logistic(auc=%0.3f)'%auc_train_cda)
plt.title('Curva ROC para data entrenamiento')
plt.xlabel('Ratio Falso positivo')
plt.ylabel('Ratio Verdarero positivo')
plt.legend()

x=[i*0.01 for i in range(100)]
y=[i*0.01 for i in range(100)]
plt.plot(x,y)
plt.show()
```

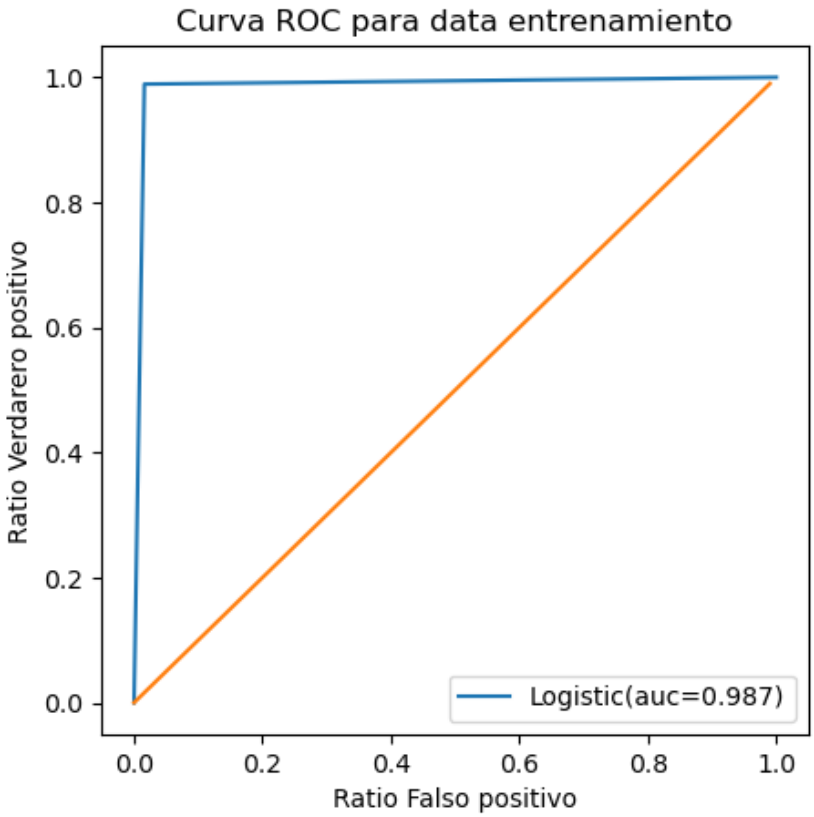

Métricas para Data de Testeo

In [71]:
```
cm_test=pd.crosstab(y_test,prob_df_test_cda["prediccion"])
cm_test
```

Out[71]:

prediccion	1	2
row_0		
1	1201	24
2	4	396

In [72]:
```
VP_test=cm_test[2][2]
VN_test=cm_test[1][1]
FP_test=cm_test[1][2]
FN_test=cm_test[2][1]
```

In [73]:
```
accuracy_test_cda=(VP_test+VN_test)/(VP_test+VN_test+FN_test+FP_test)
print('El Accuracy para la Data de Entrenamiento es:',accuracy_test_cda.round(3))
```

```
El Accuracy para la Data de Entrenamiento es: 0.983
```

In [74]:
```
sensibilidad_test_cda=(VP_test)/(VP_test+FN_test)
print('La Sensibilidad para la Data de Entrenamiento es:',sensibilidad_test_cda.round(3))
```

```
La Sensibilidad para la Data de Entrenamiento es: 0.943
```

In [75]:
```
especificidad_test_cda=(VN_test)/(VN_test+FP_test)
print('La Especificidad para la Data de Entrenamiento es:',especificidad_test_cda.round(3))
```

```
La Especificidad para la Data de Entrenamiento es: 0.997
```

In [76]:
```
#Para calcular de la curva ROC y AUC, la función roc_curve exige que las categorias sean 0 y 1
y_test_cat=np.where(y_test==1,0,1)
prob_df_test_cda['prediccion_cat']=np.where(prob_df_test_cda['prediccion']==1,0,1)

fpr,tpr,thresholds=roc_curve(y_test_cat,prob_df_test_cda['prediccion_cat'])
auc_test_cda=auc(fpr,tpr)
print('El area Bajo la Curva(AUC) para Data de Testeo es: ',auc_test_cda.round(3))
```

```
El area Bajo la Curva(AUC) para Data de Testeo es:  0.985
```

GRÁFICA CURVA ROC data testeo

In [77]:
```
plt.figure(figsize=(5,5),dpi=100)
plt.plot(fpr,tpr,linestyle='-',label='Logistic(auc=%0.3f)'%auc_test_cda)
plt.title('Curva ROC para data Testeo')
plt.xlabel('Ratio False positivo')
plt.ylabel('Ratio Verdarero positivo')
plt.legend()

x=[i*0.01 for i in range(100)]
y=[i*0.01 for i in range(100)]
plt.plot(x,y)
plt.show()
```

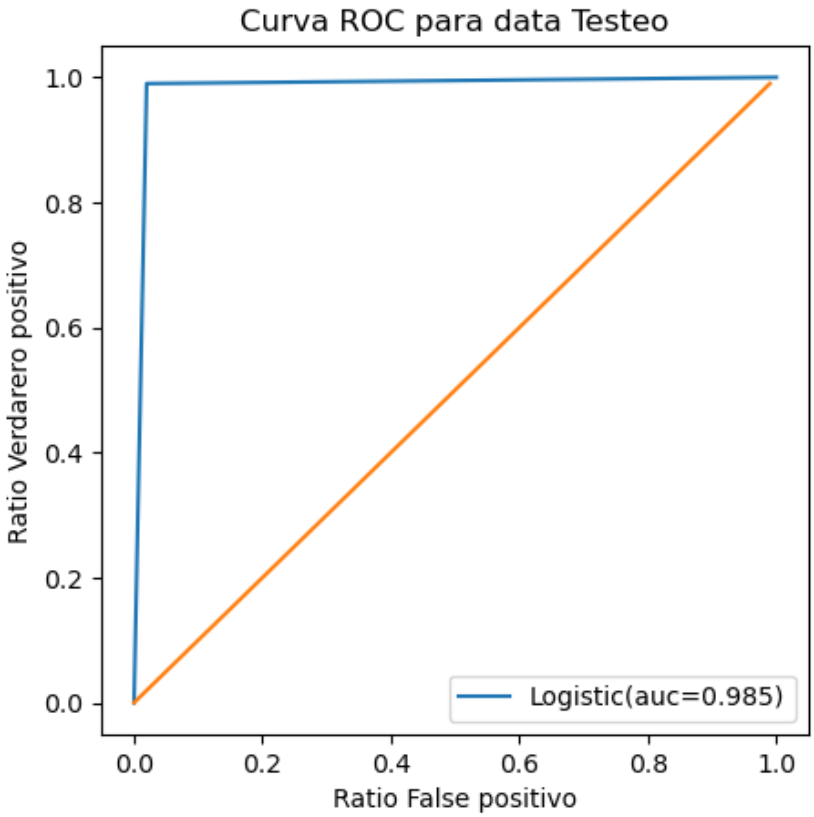

10. Realice una evaluación comentada de los tres modelos y seleccione uno de ellos (el de mejor performance) y estime la probabilidad de que el tipo de vino sea rojo teniendo en cuenta los siguientes valores para la variables:

- fixed acidity(acidez fija): 7.2
- volatile acidity(acidez volátil): 0.35
- citric acid(ácido cítrico): 0.74
- residual sugar(azúcar residual): 2.2

- chlorides(cloruros): 0.051
- free sulfur dioxide(dióxido de azufre libre): 32.0
- total sulfur dioxide(dióxido de azufre total): 183
- density(densidad): 0.98720
- pH: 3.15
- sulphates(sulfatos): 0.38
- alcohol: 12.0

RESUMEN DE MODELOS PARA DATA ENTRENAMIENTO

In [78]:
```
accuracy=[accuracy_train_log,accuracy_train_lda,accuracy_train_cda]
sensibilidad=[sensibilidad_train_log,sensibilidad_train_lda,sensibilidad_train_cda]
especificidad=[especificidad_train_log,especificidad_train_lda,especificidad_train_cda]
auc=[auc_train_log,auc_train_lda,auc_train_cda]

resumen_train=pd.DataFrame([accuracy,sensibilidad,especificidad,auc],
                           columns=['Reg.Logistica','Discriminante Lineal','Discriminante Cuadrátic
                           index=['Accuracy','Sensibilidad','Especificidad','AUC'])
resumen_train.head()
```

Out[78]:

	Reg.Logistica	Discriminante Lineal	Discriminante Cuadrático
Accuracy	0.978495	0.992955	0.986281
Sensibilidad	0.992235	0.994966	0.980165
Especificidad	0.968140	0.991362	0.991258
AUC	0.976562	0.992576	0.986568

In [79]:
```
best_accuracy=resumen_train.columns[resumen_train.loc['Accuracy',].argmax()]
best_accuracy
best_sensibilidad=resumen_train.columns[resumen_train.loc['Sensibilidad',].argmax()]
best_sensibilidad
best_especificidad=resumen_train.columns[resumen_train.loc['Especificidad',].argmax()]
best_especificidad
best_AUC=resumen_train.columns[resumen_train.loc['AUC',].argmax()]
best_AUC

print("Modelo ganador por Accuracy     : ",best_accuracy)
print("Modelo ganador por Sensibilidad : ",best_sensibilidad)
print("Modelo ganador por Especificidad: ",best_especificidad)
print("Modelo ganador por AUC          : ",best_AUC)
```

```
Modelo ganador por Accuracy     :  Discriminante Lineal
Modelo ganador por Sensibilidad :  Discriminante Lineal
Modelo ganador por Especificidad:  Discriminante Lineal
Modelo ganador por AUC          :  Discriminante Lineal
```

RESUMEN DE MODELOS PARA DATA TESTEO

In [80]:
```
accuracy=[accuracy_test_log,accuracy_test_lda,accuracy_test_cda]
sensibilidad=[sensibilidad_test_log,sensibilidad_test_lda,sensibilidad_test_cda]
especificidad=[especificidad_test_log,especificidad_test_lda,especificidad_test_cda]
auc=[auc_test_log,auc_test_lda,auc_test_cda]

resumen_test=pd.DataFrame([accuracy,sensibilidad,especificidad,auc],
                          columns=['Reg.Logistica','Discriminante Lineal','Discriminante Cuadrátic
                          index=['Accuracy','Sensibilidad','Especificidad','AUC'])
resumen_test.head()
```

Out[80]:

	Reg.Logistica	Discriminante Lineal	Discriminante Cuadrático
Accuracy	0.985231	0.993231	0.982769
Sensibilidad	0.972362	0.985037	0.942857
Especificidad	0.989405	0.995915	0.996680
AUC	0.979260	0.991301	0.985204

In [81]:
```
best_accuracy=resumen_test.columns[resumen_test.loc['Accuracy',].argmax()]
best_accuracy
best_sensibilidad=resumen_test.columns[resumen_test.loc['Sensibilidad',].argmax()]
best_sensibilidad
best_especificidad=resumen_test.columns[resumen_test.loc['Especificidad',].argmax()]
best_especificidad
best_AUC=resumen_test.columns[resumen_test.loc['AUC',].argmax()]
best_AUC

print("Modelo ganador por Accuracy     : ",best_accuracy)
print("Modelo ganador por Sensibilidad : ",best_sensibilidad)
print("Modelo ganador por Especificidad: ",best_especificidad)
print("Modelo ganador por AUC          : ",best_AUC)
```

```
Modelo ganador por Accuracy     :  Discriminante Lineal
Modelo ganador por Sensibilidad :  Discriminante Lineal
Modelo ganador por Especificidad:  Discriminante Cuadrático
Modelo ganador por AUC          :  Discriminante Lineal
```

Se puede observar que tanto para la data de entrenamiento como para la data de testeo, el modelo que más performance ha tenido a nivel de voto mayoritario bajo las métricas evaluadas es el **Modelo de Analisis Discriminante Lineal**. Procedemos a usar el modelo Discriminante Lineal para evaluar la probabilidad de que el vino sea rojo en base a los valores predeterminados.

In [86]:
```
dato_evaluacion=np.array([[7.2,0.35,0.74,2.2,0.051,32.0,183,0.98720,3.15,0.38,12.0]])
best_pred=lda_model.predict_proba(dato_evaluacion)
print("La probabilidad de que el tipo de vino sea rojo es: ", best_pred[:,1])
```

```
La probabilidad de que el tipo de vino sea rojo es:  [4.33628747e-18]
```