DESARROLLO-LABORATORIO 14: APROBACIÓN PRESIDENCIAL

In [1]:
```
import os   #Cambiar directorio de trabajo

#Manipulación de Datos
import numpy as np
import pandas as pd

#Gráficos
import matplotlib.pyplot as plt
import seaborn as sns

#Preprocesado y modelado
from scipy import stats    #Contiene a la función de pearsonr
from scipy import special  #Contiene la función softmax
from sklearn.model_selection import train_test_split #Particionamiento de datos
from sklearn.linear_model import LinearRegression #Para Análisis de Regresión Lineal
from sklearn.linear_model import RANSACRegressor #Para Análisis de Regresión RANSAC
from sklearn.metrics import r2_score #Calcula el coeficiente de determinación r2
from sklearn.metrics import mean_squared_error #Calcula el error cuadratico medio
import statsmodels.api as sm
import statsmodels.formula.api as smf
import math as m

#Just In Case
import warnings
warnings.filterwarnings('ignore')
```

In [2]:
```
#Estableciendo directorio
os.chdir("D:\Social Data Consulting\Python for Data Science\data")
```

In [3]:
```
miArchivo='Aprobacion.csv'
df=pd.read_csv(miArchivo, encoding="latin_1", sep=";")
df.head()
```

Out[3]:

	Año	Mes	IPC	Inflación	SalariosReales	CrisisDeGabinete	LunaDeMiel1	LunaDeMiel2	AñoElectoral	A
0	2006	Agosto	90.261885	0.139281	247.00	0	1	0	0	
1	2006	Septiembre	90.286647	0.027433	246.93	0	1	0	0	
2	2006	Octubre	90.326182	0.043789	246.82	0	1	0	0	
3	2006	Noviembre	90.071323	-0.282155	247.52	0	1	0	0	
4	2006	Diciembre	90.094572	0.025811	247.45	0	1	0	0	

In [4]:
```
df['Aprobación']=df['Aprobaciónn']
```

In [5]:
```
df.head()
```

Out[5]:

	Año	Mes	IPC	Inflación	SalariosReales	CrisisDeGabinete	LunaDeMiel1	LunaDeMiel2	AñoElectoral	A
0	2006	Agosto	90.261885	0.139281	247.00	0	1	0	0	
1	2006	Septiembre	90.286647	0.027433	246.93	0	1	0	0	
2	2006	Octubre	90.326182	0.043789	246.82	0	1	0	0	
3	2006	Noviembre	90.071323	-0.282155	247.52	0	1	0	0	
4	2006	Diciembre	90.094572	0.025811	247.45	0	1	0	0	

In [6]:
```
del df['Aprobaciónn']
```

In [7]:
```
df
```

Out[7]:

	Año	Mes	IPC	Inflación	SalariosReales	CrisisDeGabinete	LunaDeMiel1	LunaDeMiel2	AñoElectora
0	2006	Agosto	90.261885	0.139281	247.00	0	1	0	0
1	2006	Septiembre	90.286647	0.027433	246.93	0	1	0	0
2	2006	Octubre	90.326182	0.043789	246.82	0	1	0	0
3	2006	Noviembre	90.071323	-0.282155	247.52	0	1	0	0
4	2006	Diciembre	90.094572	0.025811	247.45	0	1	0	0
...	...	...	...	...	...	...	...	...	..
115	2016	Marzo	123.174724	0.598118	271.50	0	0	0	1
116	2016	Abril	123.188774	0.011407	271.47	0	0	0	1
117	2016	Mayo	123.446933	0.209564	307.02	0	0	0	1
118	2016	Junio	123.619152	0.139509	306.59	0	0	0	0
119	2016	Julio	123.720207	0.081747	306.34	0	0	0	0

120 rows × 13 columns

Descripción de Variables TARGET: Aprobacion--- X1: Salarios Reales--- X2: Inflación--- X3: IPC (índice de precio al consumidor)

1. Realizar un análisis exploratorio de las variables predictoras con respecto al target (matriz de dispersión y mapa de calor de las correlaciones).

In [8]:
```
columnas=['SalariosReales','Inflación','IPC','Aprobación']
```

In [9]:
```
df=df[columnas]
```

In [10]:
```
df.head()
```

Out[10]:

	SalariosReales	Inflación	IPC	Aprobación
0	247.00	0.139281	90.261885	63
1	246.93	0.027433	90.286647	58
2	246.82	0.043789	90.326182	57
3	247.52	-0.282155	90.071323	55
4	247.45	0.025811	90.094572	52

In [11]:
```
df.isnull().sum() # Sin valores nulos
```

Out[11]:
```
SalariosReales    0
Inflación         0
IPC               0
Aprobación        0
dtype: int64
```

In [12]:
```
#Con sns.pairplot podemos observar histogramas y las graficas de dispersión
sns.pairplot(df)
plt.show()
```

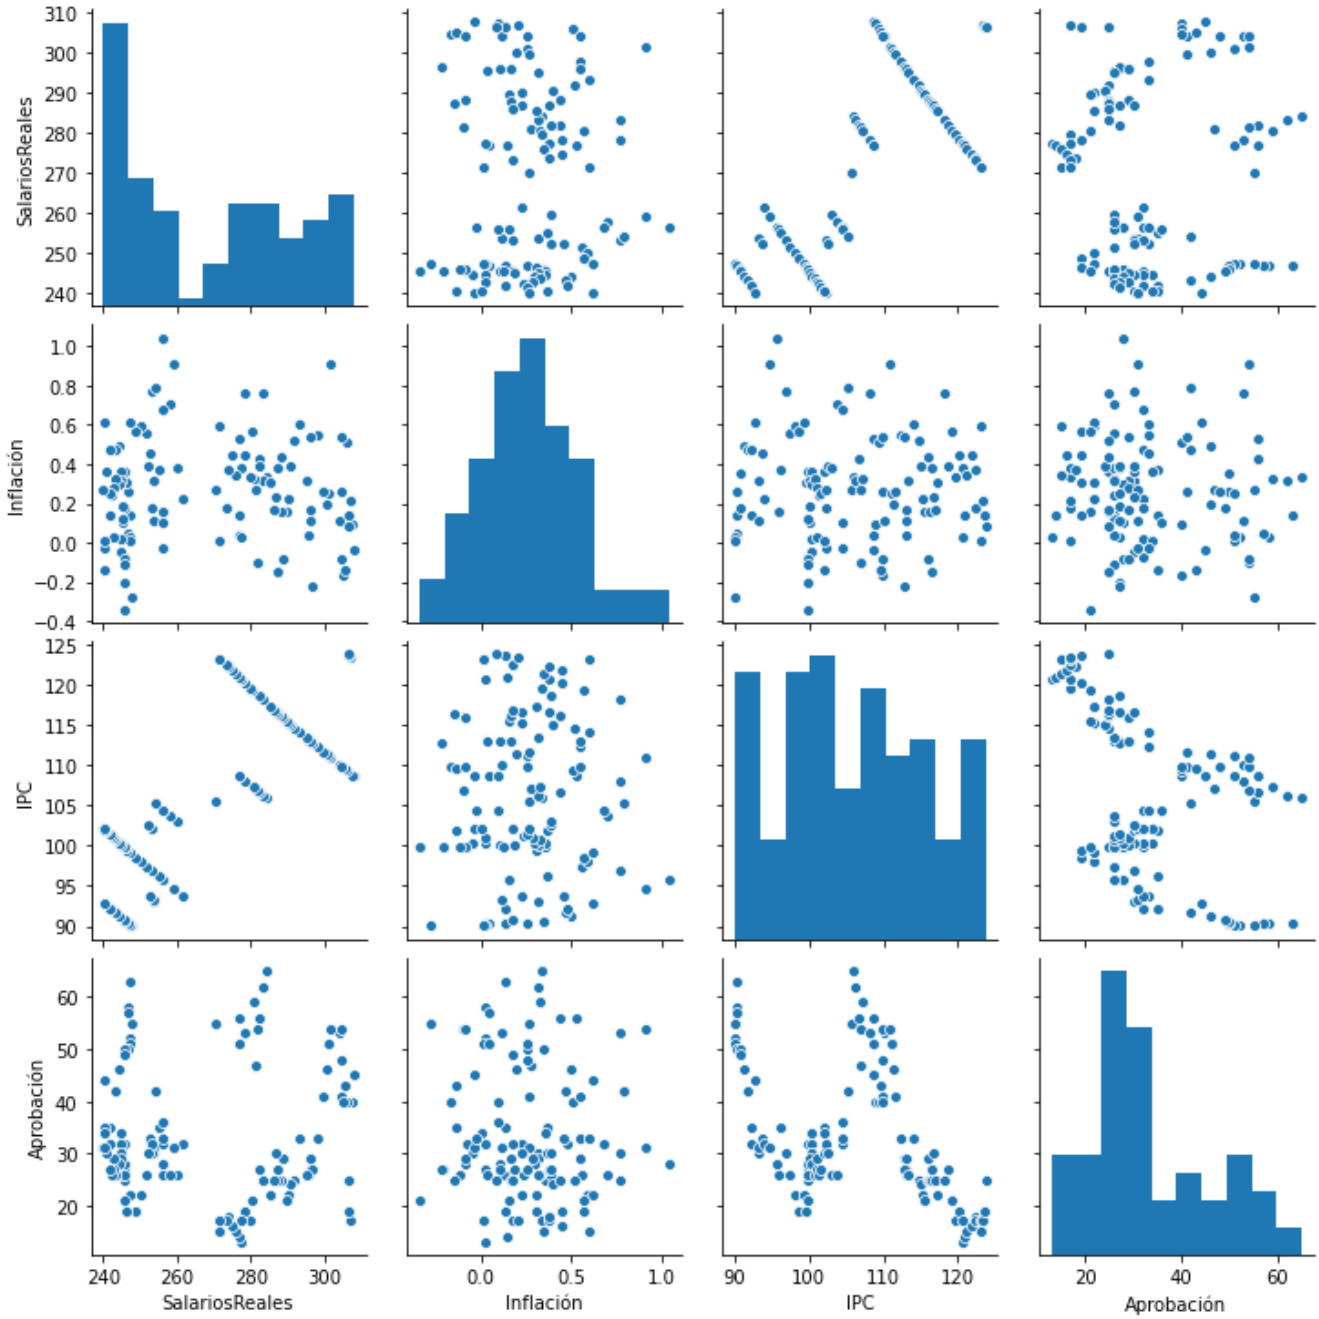

In [13]:
```
#Generando la matriz de correlaciones
cormat=np.corrcoef(df.values.T)
cormat
```

Out[13]:
```
array([[ 1.        ,  0.0164041 ,  0.75247404,  0.04432866],
       [ 0.0164041 ,  1.        ,  0.02742033, -0.06338763],
       [ 0.75247404,  0.02742033,  1.        , -0.42896134],
       [ 0.04432866, -0.06338763, -0.42896134,  1.        ]])
```

In [14]:
```
#Usando HeatMap para visualizar mejor la correlación entre variables
hm=sns.heatmap(data=cormat,
               annot=True, #Muestra los valores de las correlaciones en las celdas
               cbar=True, #barra de color a modo de saturación
               xticklabels=columnas,
               yticklabels=columnas)
plt.title('Heatmap para correlaciones')
plt.show()
```

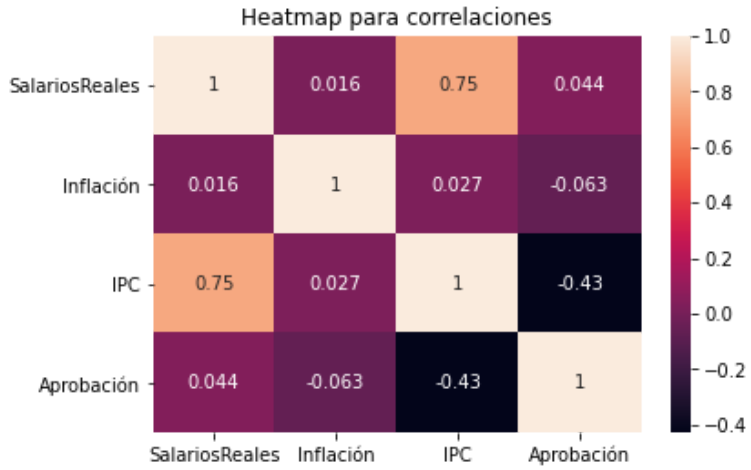

In [15]:
```
#Correlación lineal entre dos variables ('SalariosReales'-'Aprobaciónn')
cor_test=stats.pearsonr(df['SalariosReales'],df['Aprobación'])
print(cor_test)
print('El p-value es:', cor_test[1]) #El p-value es mayor a 0.5, nos da una correlación no signifi
```

```
(0.04432865519545246, 0.6306943167137045)
El p-value es: 0.6306943167137045
```

In [16]:
```
#Correlación lineal entre dos variables ('Inflación'-'Aprobaciónn')
cor_test=stats.pearsonr(df['Inflación'],df['Aprobación'])
print(cor_test)
print('El p-value es:', cor_test[1]) #El p-value es un poco menor a 0.5, nos da una correlación nc
```

```
(-0.06338762678425294, 0.4915782274933316)
El p-value es: 0.4915782274933316
```

In [17]:
```
#Correlación lineal entre dos variables ('IPC'-'Aprobaciónn')
cor_test=stats.pearsonr(df['IPC'],df['Aprobación'])
print(cor_test)
print('El p-value es:', cor_test[1])  #El p-value es muy pequeño, tiende a 0 , nos da una correlac
```

```
(-0.42896133654330026, 1.0170266803445158e-06)
El p-value es: 1.0170266803445158e-06
```

2.Construir los datos de entrenamiento y de prueba, teniendo en cuenta que 70% de los datos es para entrenamiento y 30% de prueba.

Caso Regresion lineal Simple

In [18]:
```
#Establecer nuestra matriz de datos X y variable target Y (Para regresion lineal simple)
Xrls=df[['SalariosReales']]
yrls=df[['Aprobación']]
```

In [19]:
```
X_trainrls,X_testrls,y_trainrls,y_testrls=train_test_split(Xrls,
                                                           yrls,
                                                           test_size=0.3,
                                                           random_state=2020)
```

Caso Regresion Lineal Multiple

In [20]:
```
#Establecer nuestra matriz de datos X y variable target Y (Para regresion lineal multiple)
Xrlm=df.iloc[:,:3].values
yrlm=df.iloc[:,3].values
```

In [21]:
```
X_trainrlm,X_testrlm,y_trainrlm,y_testrlm=train_test_split(Xrlm,
                                                           yrlm,
                                                           test_size=0.3,
                                                           random_state=2020)
```

3.Realizar un modelo de regresión lineal simple: TARGET ~ X1

In [22]:
```
#Creando una instancia LinearRegression()
modelorls=LinearRegression()
```

In [23]:
```
#Hacemos que el modelo aprenda de los datos
modelorls.fit(X_trainrls,y_trainrls)
```

Out[23]:
```
LinearRegression()
```

In [24]:
```
#Información del Modelo
#=====================================
print("El interceptor del modelo es :",modelorls.intercept_.round(3))
print("La pendiente del modelo es:",modelorls.coef_[0].round(3))
print("El coeficiente de determinacion R2 es:", (modelorls.score(X_trainrls,y_trainrls)*100).round
```

```
El interceptor del modelo es : [38.336]
La pendiente del modelo es: [-0.018]
El coeficiente de determinacion R2 es: 0.11 %
```

In [25]:
```
#Estimacion de la variable Dependiente o YPredicho
ytrainrls_pred=modelorls.predict(X_trainrls)
ytestrls_pred=modelorls.predict(X_testrls)
```

Evaluacion de Modelos (RMSE)

In [26]:
```
#para data de entrenamiento
round(m.sqrt(mean_squared_error(y_trainrls,ytrainrls_pred)),3)
```

Out[26]:
```
12.256
```

In [27]:
```
#para data de testing
round(m.sqrt(mean_squared_error(y_testrls,ytestrls_pred)),3)
```

Out[27]:
```
13.447
```

Evaluacion de Modelos (R2)

Evaluación de Modelos (R2)

In [28]:
```
#para data de entrenamiento
round(r2_score(y_trainrls,ytrainrls_pred),3)
```

Out[28]: 0.001

In [29]:
```
#para data de testing
round(r2_score(y_testrls,ytestrls_pred),3)
```

Out[29]: -0.014

Resumen de metricas del modelo

In [30]:
```
X_constant=sm.add_constant(Xrls)
lin_reg= sm.OLS(yrls,X_constant).fit()
lin_reg.summary()
```

Out[30]:

OLS Regression Results

Dep. Variable:	Aprobación	**R-squared:**	0.002
Model:	OLS	**Adj. R-squared:**	-0.006
Method:	Least Squares	**F-statistic:**	0.2323
Date:	Wed, 28 Apr 2021	**Prob (F-statistic):**	0.631
Time:	15:28:37	**Log-Likelihood:**	-474.20
No. Observations:	120	**AIC:**	952.4
Df Residuals:	118	**BIC:**	958.0
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	26.7838	13.810	1.939	0.055	-0.563	54.131
SalariosReales	0.0247	0.051	0.482	0.631	-0.077	0.126

Omnibus:	9.781	**Durbin-Watson:**	0.116
Prob(Omnibus):	0.008	**Jarque-Bera (JB):**	10.028
Skew:	0.666	**Prob(JB):**	0.00664
Kurtosis:	2.521	**Cond. No.**	3.21e+03

Warnings:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 3.21e+03. This might indicate that there are
strong multicollinearity or other numerical problems.

In [31]:
```
#Creando una función para visualizar los datos y la recta de regresión
def lin_regplot(X,y,model):
    plt.scatter(X,y,c='blue')
    plt.plot(X,model.predict(X),color='red')
    return
```

Graficando mis datos de entrenamiento

In [32]:
```
lin_regplot(X_trainrls,y_trainrls,modelorls)
plt.title('Datos de Entrenamiento')
plt.xlabel('Salario Promedio')
plt.ylabel('Cantidad de Aprobacion')
plt.show()
```

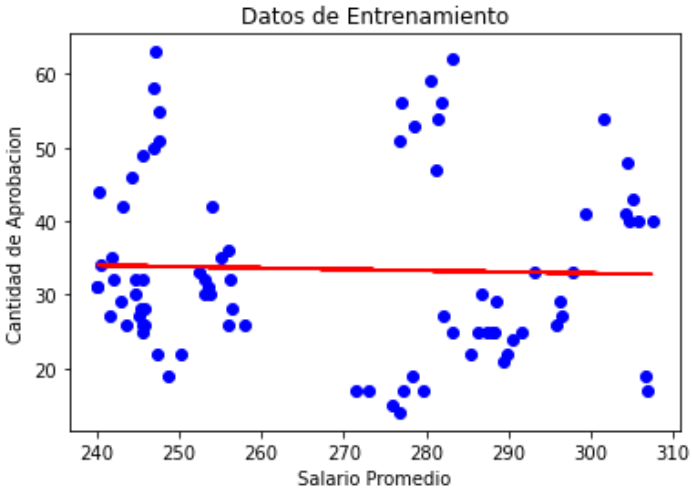

In [33]:
```
lin_regplot(X_testrls,y_testrls,modelorls)
plt.title('Datos de Entrenamiento')
plt.xlabel('Salario Promedio')
plt.ylabel('Cantidad de Aprobacion')
plt.show()
```

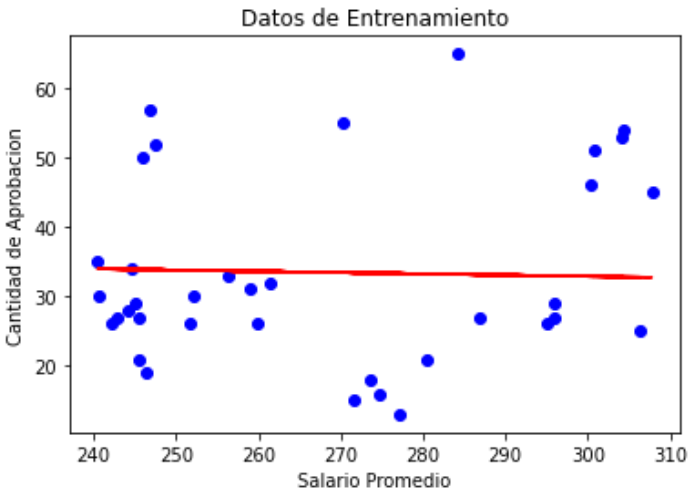

4.Realizar un modelo de regresión lineal múltiple: TARGET ~ X1 +X2 +X3

In [34]:
```
#Instnanciar un objeto de clase LinearRegression()
modelorlm=LinearRegression()
#Hacer que nuestro modelo aprenda de los datos
modelorlm.fit(X_trainrlm,y_trainrlm)
```

Out[34]:
```
LinearRegression()
```

In [35]:
```
#Estimar los valores de Ypredicho
y_trainrlm_pred=modelorlm.predict(X_trainrlm)
y_testrlm_pred=modelorlm.predict(X_testrlm)
```

In [36]:
```
#Evaluando el coeficiente de determinacon R2
print("Coeficiente de Determinacion-Training",r2_score(y_trainrlm,y_trainrlm_pred).round(2))
print("Coeficiente de Determinacion-Testing",r2_score(y_testrlm,y_testrlm_pred).round(2))
```

```
Coeficiente de Determinacion-Training 0.46
Coeficiente de Determinacion-Testing 0.56
```

In [37]:
```
#Evaluando el MSE
print("RMSE-Training",round(m.sqrt(mean_squared_error(y_trainrlm,y_trainrlm_pred)),2))
print("RMSE-Testing",round(m.sqrt(mean_squared_error(y_testrlm,y_testrlm_pred)),2))
```

```
RMSE-Training 8.98
RMSE-Testing 8.87
```

Resumen de metricas del modelo

In [38]:
```
X_constant=sm.add_constant(Xrlm)
lin_reg= sm.OLS(yrlm,X_constant).fit()
lin_reg.summary()
#X1: Salarios Reales
#X2: Inflación
#X3: IPC (índice de precio al consumidor)
```

Out[38]:

OLS Regression Results

Dep. Variable:	y	**R-squared:**	0.497
Model:	OLS	**Adj. R-squared:**	0.484
Method:	Least Squares	**F-statistic:**	38.21
Date:	Wed, 28 Apr 2021	**Prob (F-statistic):**	3.02e-17
Time:	15:28:38	**Log-Likelihood:**	-433.09
No. Observations:	120	**AIC:**	874.2
Df Residuals:	116	**BIC:**	885.3
Df Model:	3		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	54.1743	10.224	5.299	0.000	33.924	74.424
x1	0.4711	0.056	8.460	0.000	0.361	0.581
x2	-2.2769	3.119	-0.730	0.467	-8.455	3.901
x3	-1.3834	0.130	-10.640	0.000	-1.641	-1.126

Omnibus:	8.474	**Durbin-Watson:**	0.338
Prob(Omnibus):	0.014	**Jarque-Bera (JB):**	8.593
Skew:	0.653	**Prob(JB):**	0.0136
Kurtosis:	3.117	**Cond. No.**	3.57e+03

Warnings:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 3.57e+03. This might indicate that there are
strong multicollinearity or other numerical problems.

Grafica

In [39]:
```
sns.pairplot(df,x_vars=['SalariosReales','Inflación','IPC'],y_vars=['Aprobación'],kind='reg',aspec
plt.show()
```

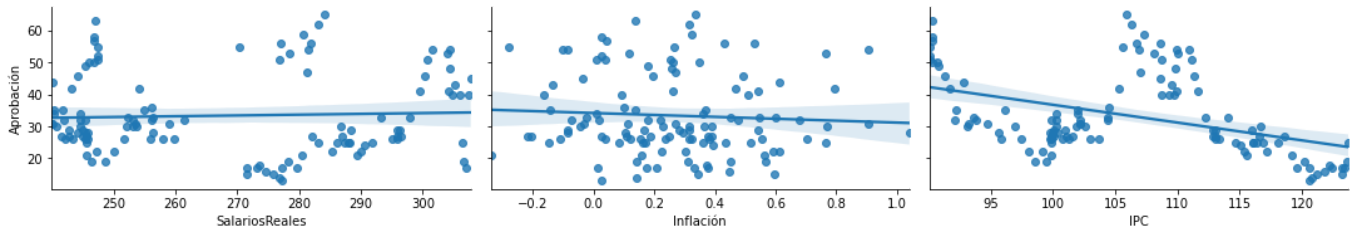

In [ ]:
```
```

/